

Rapport de projet - Analyse de données, reporting et datavisualisation

FACTEURS DE MORTALITE EN SOINS INTENSIFS

Enseignants : Sabrina Bendimerad et Laurent Orsi

Groupe 13 : Eda BASARAN et Santatriniaina RASOLOFOMANANA

Groupe 14 : Christella DAVID et Anthony EL DAHDAH

SOMMAIRE

INTRODUCTION.....3

1. PRESENTATION DES DONNEES.....4 à 7

1.1. Description de la base de données.....4

1.2. Variables sélectionnées pour l'analyse de la base de données.....4 et 5

1.3. Statistiques descriptives rapides sur quelques variables.....5 à 7

1.3.1. Vue d'ensemble des variables.....5

1.3.2. Analyse univariée.....5 à 7

2. ANALYSE APPROFONDIE DES FACTEURS ASSOCIES A LA MORTALITE.....8 à 15

2.1. Exploration croisée des variables et de la mortalité : Analyse bivariée....8 à 12

2.2. Évaluation statistique des liens significatifs avec la mortalité : tests d'hypothèses.....12 à 14

2.3. Analyse du risque de décès par modélisation logistique multivariée....14 et 15

CONCLUSION.....16

TABLE DES ILLUSTRATIONS.....17 et 18

I : Vue d'ensemble des variables.....17

II : Analyse univariée.....17 et 18

III : Tests statistiques : Variables qualitatives.....18

IV : Tests statistiques : Variables quantitatives.....18

ANNEXES

I : Statistiques descriptives rapides : Programme R.....19 et 20

II : Analyse bivariée : Aperçu du Programme R.....21

III : Tests statistiques : Programme R.....22

IV : Modèle logistique : Programme R.....22

INTRODUCTION

Le jeu de données à analyser provient d'une étude observationnelle multicentrique (cinq centres hospitaliers) réalisée aux États-Unis. Cette étude porte sur 5 500 patients adultes (≥ 18 ans) admis en unité de soins intensifs (USI) entre juin 1989 et janvier 1994, et suivis pendant six mois. Dans le cadre de l'analyse des facteurs influençant la mortalité des patients, nous avons entrepris un processus rigoureux d'analyses statistiques de la base de données. Les données brutes, issues du fichier *Epi_clin2024.txt*, comportent 67 variables classées en différentes catégories.

La problématique retenue est la suivante : **Comment les éléments liés à l'état des patients déterminent-ils leur risque de mortalité en soins intensifs ?**

Ce choix repose sur son importance clinique et scientifique. La mortalité en soins intensifs constitue un enjeu majeur, et comprendre les facteurs influençant la survie des patients permettrait d'améliorer leur prise en charge et d'optimiser les protocoles médicaux. De plus, cette étude observationnelle multicentrique fournit une base de données riche en informations cliniques, sociodémographiques et physiologiques, offrant ainsi une opportunité unique d'identifier les variables les plus déterminantes. L'analyse de ces facteurs peut également contribuer au développement de modèles prédictifs permettant d'anticiper le risque de décès et d'adapter les traitements en conséquence.

Afin de répondre à cette problématique, notre étude se décompose en deux parties principales. Dans un premier temps, nous présenterons les données ainsi que les variables sélectionnées, accompagnées de statistiques descriptives pour mieux comprendre la nature de l'échantillon. Dans un second temps, nous analyserons en profondeur les facteurs associés à la mortalité, à travers une exploration bivariée, des tests statistiques d'association, puis une modélisation du risque de décès par régression logistique multivariée.

Hypothèses

Tout d'abord, nous supposons que l'âge du patient influence le risque de mortalité : les patients plus âgés présentent un risque plus élevé que les plus jeunes. Ensuite, la gravité de l'état initial, notamment la présence de maladies chroniques telles que le diabète, l'insuffisance rénale ou les pathologies cardiovasculaires, constitue un facteur déterminant du risque de décès. Enfin, les paramètres physiologiques initiaux, tels qu'une pression artérielle basse, une fréquence cardiaque élevée ou une saturation en oxygène faible, sont des marqueurs de mauvais pronostic, traduisant souvent une défaillance des organes vitaux.

1. PRÉSENTATION DES DONNÉES

1.1. Description de la base de données

Nous disposons des données réelles issues d'une étude observationnelle multicentrique sur 5 hôpitaux réalisée aux États-Unis. Le jeu de données regroupe différentes variables classées par catégorie : diagnostic à l'admission, maladies associées, scores cliniques, caractéristiques physiologiques, événements, dates et caractéristiques sociodémographiques. Leur mode de collecte varie selon la catégorie. Par exemple, les données sociodémographiques ont été recueillies par questionnaire lors de l'admission en USI, tandis que les caractéristiques cliniques ont été mesurées le jour suivant.

Les types de données à exploiter sont numériques (0,1, 65, etc.) comme les variables AGE, WTKILO1, MEANBP1, etc., et textuels (yes, no, coma, etc.) comme CAT1, CAT2, CA, etc.

1.2. Variables sélectionnées pour l'analyse de la base de données

Pour répondre à la problématique de l'étude, nous avons d'abord sélectionné notre variable centrale, DEATH, qui représente le décès des patients durant le suivi. Elle a été retenue pour l'analyse principale de notre sujet. Par la suite, nous avons sélectionné les critères pertinents qui peuvent être liés à la mort des patients en soin intensif. Ces critères sont les suivants :

- **Critères cliniques :** nous avons sélectionné des variables liées :
 - au **diagnostic à l'admission** (CARD : cardiovasculaire, SEPS : Infectieux), afin de déterminer l'origine des pathologies des patients et évaluer si certains diagnostics augmentent le risque de mortalité en soins intensifs ;
 - aux **maladies associées** (CHRPULHX : Atteinte pulmonaire, RENALHX : Atteinte rénale, IMMUNHX : Immunosuppression/ VIH/ Diabète), car ces problèmes de santé supplémentaires peuvent aggraver l'état général des patients et influencer leur réponse au traitement, affectant ainsi leur risque de décès ;
 - aux **scores cliniques** (SURV2MD1 : Probabilité estimée de survie à 2 mois, APS1 : Score Apache 3, SCOMA1 : Score Glasgow), qui permettent d'évaluer de manière objective l'état clinique global des patients et d'estimer leur risque de mortalité en soins intensifs. Cependant, la variable ADLD3P (évaluant les capacités des patients dans les activités quotidiennes) a été exclue, car elle contenait 4113 valeurs manquantes, donc elle est inexploitable.
- **Critères physiologiques :** Les variables choisies incluent des **paramètres vitaux** et biologiques comme le **poids** (WTKILO1), la **tension artérielle** (MEANBP1), la **fréquence respiratoire** (RESP1) et **cardiaque** (HRT1), ainsi que les **leucocytes** (WBLC1), pour évaluer les globules blancs qui jouent un rôle essentiel dans la défense immunitaire de l'organisme. Ces variables sont essentielles pour l'évaluation des risques et de l'état de santé des patients.

- **Critères sociodémographiques** : L'âge a été conservé comme critère sociodémographique, car il est essentiel dans l'évaluation de la vulnérabilité et des risques associés aux pathologies.

1.3. Statistiques descriptives rapides sur quelques variables (*Annexe I*)

1.3.1. Vue d'ensemble des variables (*Table des illustration I*)

Il est important de se familiariser avec les données utilisées. Nous proposons ici un aperçu statistique rapide des variables clés qui serviront à étudier les facteurs influençant la mortalité en soins intensifs.

Les variables qualitatives comprennent notamment **DEATH** (statut de mortalité), **CARD**, **SEPS** et **SWANG1**, toutes codées en deux modalités, sans valeurs manquantes.

Parmi les variables quantitatives, l'âge moyen des patients est de 61,7 ans, avec des valeurs allant de 18 à 102 ans. Le poids moyen est de 74,4 kg, avec une plage allant de 19,5 à 209 kg.

Les paramètres physiologiques initiaux montrent une grande dispersion : la pression artérielle moyenne (MEANBP1) varie entre 0 et 259 mmHg, avec une moyenne de 77,4 mmHg, tandis que la fréquence cardiaque (HRT1) varie de 0 à 250 battements par minute, avec une moyenne de 115.


Les scores cliniques tels que APS1 et SCOMA1 présentent également une large variation, reflétant les différences de gravité parmi les patients.

Cet aperçu statistique rapide permet de mieux comprendre la distribution et la nature des données utilisées pour l'analyse des facteurs de mortalité.

1.3.2. Analyse univariée



Il est important de décrire individuellement les principales variables de notre base de données. Cette étape permet de comprendre la distribution et la variabilité des données, et de poser les bases pour les analyses suivantes. Nous présentons ici trois variables clés, représentatives de la population et des critères étudiés, tandis que les autres sont dans la table des illustrations.

Les graphiques complémentaires (*Table des illustrations II*), apportent un éclairage important sur d'autres aspects cliniques. Le diagramme de Venn révèle que la plupart des patients présentent soit des maladies cardiovasculaires, soit des infections, avec une part notable de comorbidités. La variabilité du nombre de leucocytes est élevée, indiquant des réponses immunitaires très différentes selon les patients. La fréquence cardiaque, généralement supérieure à la normale, témoigne du stress physiologique important lié à leur état critique. Le score neurologique montre que la majorité des patients ont un état sévèrement altéré, avec peu de cas moins graves. Enfin, la cathétérisation, pratiquée chez une minorité, semble réservée à des cas spécifiques, ce qui pourrait influencer l'évolution clinique et la mortalité.




Ce premier graphique montre la répartition des patients décédés pendant leur séjour en soins intensifs. On voit que 66 % des patients sont décédés, contre 34 % qui ont survécu. Cette forte mortalité montre que les patients sont très gravement malades. Cela justifie l'importance d'étudier les facteurs qui influencent leur survie, comme l'âge, les scores cliniques ou les signes vitaux.

Ce deuxième graphique illustre la répartition de l'âge des patients. La majorité se situe entre 60 et 80 ans, tandis que les patients très jeunes ou très âgés sont moins nombreux. Cette distribution souligne l'importance de l'âge comme facteur de risque, puisque les patients plus âgés sont généralement plus vulnérables et exposés à un risque accru de complications.



Le troisième graphique présente la distribution des scores de gravité à l'admission. Un score de gravité élevé signifie que le patient est dans un état critique, avec des fonctions vitales très perturbées et un risque de mortalité important. À l'inverse, un score faible reflète un état de santé plus stable. Ici, la plupart des patients ont un score entre 30 et 59, ce qui indique un état de santé modéré à sévère. Les cas très graves ou très légers sont plus rares. Ce score est un indicateur essentiel du risque de mortalité et doit être pris en compte dans l'analyse.



Ce graphique représente la répartition des **patients selon leur probabilité de vivre encore 2 mois**. On observe que la majorité des patients (environ **43%**) ont **une probabilité comprise entre 0,6 et 0,8**, ce qui est plutôt encourageant. Cela signifie qu'ils ont de bonnes chances de survivre à court terme. Environ **27%** des patients ont une probabilité entre **0,4 et 0,6**,

ce qui montre une situation incertaine. Un peu plus de 14% des patients ont une probabilité entre 0.8 et 1. Les patients avec une probabilité inférieure à 0,4 sont minoritaires (environ **17% au total**), ce qui indique que peu de patients sont dans un état critique dans un court terme.


2. ANALYSE APPROFONDIE DES FACTEURS ASSOCIES A LA MORTALITE


2.1. Exploration croisée des variables et de la mortalité : Analyse bivariée

Après avoir décrit individuellement les principales variables (analyse univariée), nous avons réalisé une exploration croisée de ces variables avec la mortalité (DEATH), notre variable d'intérêt. À l'aide de graphiques bivariés, nous avons comparé visuellement les distributions ou proportions entre patients décédés et survivants. Cette approche permet d'identifier les facteurs qui pourraient être associés à un risque plus élevé de décès en soins intensifs, tels que l'âge, les diagnostics, les scores de gravité, ou encore certains paramètres biologiques et physiologiques. Cette étape constitue une première analyse exploratoire avant les tests statistiques plus poussés. (*Annexe II*)

CRITERES CLINIQUES


Les différentes conditions médicales représentées sur les graphiques ci-dessous (comme la **maladie cardiovasculaire**, la **présence d'infection**, l'**atteinte pulmonaire**, l'**insuffisance rénale**, la **mise en place du cathéter de Swan-Ganz** et l'**immunosuppression**) montrent des barres très proches entre les patients décédés et survivants. Cette **stabilité visuelle** suggère qu'aucune de ces variables ne semble avoir un **effet impactant** sur la mortalité dans cet échantillon. En revanche, une analyse statistique plus approfondie sera nécessaire pour confirmer s'il existe des **différences significatives**.






Ce graphique montre la **relation entre le score Apache 3 et la mortalité** en soins intensifs. La distribution met en évidence une tendance claire : **plus le score est élevé, plus le nombre de décès est important**. Cette relation suggère que les patients ayant des scores élevés présentent une **gravité clinique accrue**, ce qui augmente significativement leur risque de mortalité. Ce score intègre plusieurs paramètres biologiques, et son augmentation reflète une détérioration de l'état physiologique des patients admis.

Ce graphique montre la **relation entre le score de Glasgow et la mortalité** en soins intensifs. On observe une **tendance légèrement croissante**, indiquant que plus le score augmente, plus le nombre de décès est important. Cette progression, bien que présente, n'est pas aussi marquée que pour d'autres indicateurs, suggérant que l'impact du score de Glasgow sur la mortalité peut varier selon les patients et leurs conditions médicales.





CRITERES PHYSIOLOGIQUES



Ce graphique représente la **relation entre le poids des patients et la mortalité** en soins intensifs. La distribution des décès en fonction du poids semble présenter une certaine variation, indiquant que certaines plages de poids, notamment entre [180-199] pourraient être associées à un risque plus élevé de décès.


L'observation de ces tendances est essentielle pour comprendre l'impact du poids sur la survie des patients hospitalisés. Des valeurs extrêmes, qu'elles soient faibles ou élevées, pourraient jouer un rôle clé dans la vulnérabilité des individus face aux soins intensifs.


Une tension artérielle élevée est généralement associée à un risque accru de complications cardiovasculaires. Cependant, sur ce graphique, on observe que la proportion de décès est plus importante dans les classes de tension artérielle comprises entre 0 et 100 mmHg, comparativement aux classes supérieures à 100 mmHg. Au-delà de 100 mmHg, la distribution des décès semble relativement homogène, sans variation marquée entre les différentes classes. Par conséquent, aucune conclusion claire ne peut être tirée quant à l'impact de la tension artérielle élevée sur la mortalité.



Une fréquence respiratoire élevée peut refléter une détresse respiratoire ou un stress physiologique important chez les patients. Cependant, l'analyse visuelle de ce graphique montre une distribution relativement homogène de la mortalité à travers les différentes classes de fréquence respiratoire. Ainsi, aucune association significative ne semble émerger entre la fréquence respiratoire et le risque de décès.

Une fréquence cardiaque élevée peut indiquer une réponse physiologique au stress, une tachycardie pouvant être associée à une défaillance cardiovasculaire ou à une détresse aiguë. À l'inverse, une fréquence cardiaque basse peut refléter un ralentissement cardiaque pathologique (bradycardie) ou une altération de la fonction autonome. Une élévation significative de la fréquence cardiaque au-delà de certains seuils (par exemple >100 bpm) peut alerter sur un risque accru de complications. Cependant, le graphique montre une distribution homogène de la mortalité, avec environ 70 % des patients décédés répartis de manière constante quelle que soit la classe de fréquence cardiaque. Cela suggère que la fréquence cardiaque seule ne semble pas être un facteur discriminant du risque de décès.






Un taux de leucocytes élevé peut refléter une réaction inflammatoire importante, une infection sévère ou une réponse immunitaire exacerbée. À l'inverse, un taux bas de leucocytes peut indiquer une immunosuppression ou une défaillance médullaire, exposant le patient à un risque infectieux accru. Des valeurs élevées, généralement supérieures à $100 \times 10^9/L$, sont préoccupantes car elles peuvent signaler une pathologie grave. Sur ce graphique, on observe que la mortalité est particulièrement élevée dans la plage comprise entre 100 et

192, avec environ 95 % des patients décédés appartenant à cette catégorie, ce qui suggère une association forte entre un taux élevé de leucocytes et un risque accru de décès en soins intensifs.

CRITERE SOCIODEMOGRAPHIQUE

Ce graphique est une représentation de la proportion des décès par classe d'âge en soins intensifs. Il met en évidence une relation croissante entre l'âge et la proportion de décès. La forme en escalier montre une augmentation progressive de la mortalité à mesure que l'âge avance, indiquant que les patients plus âgés sont davantage touchés. Cette tendance souligne l'importance de l'âge comme facteur clé influençant la survie, possiblement en raison de l'accumulation de comorbidités et d'une réduction des capacités physiologiques à faire face à des conditions critiques.



Les graphiques suggèrent que certaines conditions médicales comme les maladies cardiovasculaires, infectieuses, pulmonaires ou rénales, ainsi que l'immunosuppression, n'ont pas d'effet évident sur la mortalité dans cet échantillon. Cependant, cette observation reste visuelle et il est nécessaire de réaliser des tests statistiques pour confirmer s'il existe ou non une association réelle.

En revanche, l'âge des patients montre une tendance claire : plus les patients sont âgés, plus leur risque de décès augmente. De même, les scores cliniques (Apache 3, Glasgow) et la probabilité estimée de survie à 2 mois semblent bien liés au risque de mortalité, avec un risque plus élevé chez les patients les plus sévèrement atteints. Le poids pourrait aussi jouer un rôle, avec certaines plages associées à un risque accru, mais cette tendance est moins marquée.

Ces observations sont une première indication des facteurs qui pourraient influencer la mortalité, mais elles doivent être validées par des analyses statistiques plus approfondies pour être confirmées.

2.2. Évaluation statistique des liens significatifs avec la mortalité : tests d'hypothèses

Dans le cadre de notre projet, après une première phase d'analyse bivariée descriptive à l'aide de visualisations, nous avons constaté que ces méthodes, bien qu'utiles pour explorer les données, ne suffisent pas à répondre à la problématique de manière rigoureuse. Nous avons donc poursuivi notre démarche par des tests statistiques afin d'évaluer les associations entre certaines variables et la mortalité des patients (variable DEATH). Pour cela, nous avons appliqué différentes procédures selon le type de variable. (*Annexe III*)

Pour les variables qualitatives (comme les antécédents médicaux ou certaines conditions cliniques), nous avons eu recours au test du χ^2 d'indépendance (`chisq.test()` dans R) lorsque les effectifs observés étaient suffisants, ou au test exact de Fisher (`fisher.test()`) dans les cas de faibles effectifs. Les variables analysées étaient notamment les antécédents cardiovasculaires (CARD), la présence de septicémie (SEPS), une pathologie pulmonaire chronique (CHRPULHX), une insuffisance rénale chronique (RENALHX) et l'immunodépression (IMMUNHX). Voici les résultats obtenus (*Table des illustrations III*):

a) CARD (Diagnostic cardiovasculaire) vs mortalité :

- $\chi^2 = 1.89$, $p = 0.1688$
- L'association entre la présence d'un diagnostic cardiovasculaire à l'admission et la mortalité en soins intensifs n'est pas statistiquement significative ($p > 0.05$). Cela suggère qu'ici, la présence d'une pathologie cardiovasculaire ne semble pas augmenter significativement le risque de décès.

b) SEPS (Diagnostic infectieux) vs mortalité :

- $\chi^2 = 5.56$, $p = 0.01841$
- L'association est significative ($p < 0.05$), indiquant que la présence d'une infection augmente le risque de mortalité en soins intensifs. Le diagnostic infectieux constitue donc un facteur de risque important.

c) CHRPULHX (Atteinte pulmonaire) vs mortalité :

- $\chi^2 = 4.39$, $p = 0.03622$
- L'atteinte pulmonaire est aussi associée de façon significative à une augmentation du risque de décès ($p < 0.05$), confirmant son impact négatif sur le pronostic.

d) RENALHX (Atteinte rénale) vs mortalité :

- $\chi^2 = 2.31$, $p = 0.1284$

- L'association n'est pas statistiquement significative ($p > 0.05$), suggérant qu'une atteinte rénale, dans ce jeu de données, ne constitue pas un facteur de risque indépendant de mortalité.

e) **IMMUNHX (Immunosuppression/VIH/Diabète) vs mortalité :**

- Test exact de Fisher, $p = 0.00413$, OR = 1.22 (Intervalle de Confiance 95% : 1.06 – 1.40)
- L'immunosuppression est associée à un risque significativement plus élevé de mortalité ($p < 0.01$), avec une augmentation des chances de décès d'environ 22%. Cela confirme que les patients immunodéprimés sont plus vulnérables.

Pour les variables quantitatives continues, telles que l'âge, les scores cliniques ou les constantes vitales, nous avons utilisé le test t de Student (t.test) afin de comparer les moyennes entre les patients décédés et non décédés. (*Table des illustrations IV*)

f) **APS1 (Score Apache 3) vs mortalité :**

- $t = -4.64$, $p = 3.7 \times 10^{-6}$
- La différence de score APS1 entre les patients décédés et non décédés est statistiquement significative ($p < 0.001$). Les patients décédés présentent un score APS1 moyen plus élevé, indiquant un état clinique plus sévère associé à un risque accru de mortalité.

g) **SCOMA1 (Score Glasgow) vs mortalité :**

- $t = -7.39$, $p = 1.75 \times 10^{-13}$
- Une différence très significative est observée entre les groupes, avec un score Glasgow moyen plus élevé chez les patients décédés, ce qui reflète une gravité clinique accrue.

h) **SURV2MD1 (Probabilité estimée de survie à 2 mois) vs mortalité :**

- $t = 27.32$, $p < 2.2 \times 10^{-16}$
- La probabilité estimée de survie est significativement plus faible chez les patients décédés, confirmant son rôle prédictif important dans l'évaluation du risque de mortalité.

i) **MEANBP1 (Pression artérielle moyenne) vs mortalité :**

- $t = 6.38$, $p = 2.08 \times 10^{-10}$
- La pression artérielle moyenne est significativement plus basse chez les patients décédés, ce qui peut témoigner d'une instabilité hémodynamique associée à un pronostic défavorable.

j) **RESP1 (Fréquence respiratoire) vs mortalité :**

- $t = -0.25$, $p = 0.80$
- Aucune différence significative n'a été détectée entre les groupes pour la fréquence respiratoire.

k) **HRT1 (Fréquence cardiaque) vs mortalité :**

- $t = 1.44$, $p = 0.15$
- La fréquence cardiaque ne montre pas de différence significative entre patients décédés et non décédés.

l) **WBLC1 (Leucocytes) vs mortalité :**

- $t = -1.56$, $p = 0.12$
- Aucun effet significatif des taux de leucocytes n'est observé en lien avec la mortalité.

m) **AGE (Âge) vs mortalité :**

- $t = -14.10$, $p < 2.2 \times 10^{-16}$
- L'âge moyen des patients décédés est significativement plus élevé que celui des survivants, indiquant que l'âge est un facteur de risque majeur de mortalité en soins intensifs.

Ces tests statistiques révèlent que plusieurs facteurs, infection, immunodépression, scores cliniques, pression artérielle et âge, sont significativement liés à la mortalité. Les p-values inférieures à 0,05 confirment que les différences entre patients décédés et survivants sont statistiquement significatives, ce qui souligne leur influence réelle sur le risque de décès.

On peut donc conclure que la mortalité en soins intensifs dépend de la gravité clinique, de l'état immunitaire, de la présence d'infections et de l'âge. Les patients plus âgés, immunodéprimés ou atteints d'infections graves présentent un risque accru, ce qui justifie une surveillance attentive et une prise en charge adaptée pour améliorer leur pronostic.

2.3. Analyse du risque de décès par modélisation logistique multivariée

Afin de compléter les analyses statistiques réalisées précédemment et de mieux comprendre les facteurs associés à la mortalité en réanimation, nous avons mis en place un modèle de régression logistique. Ce type de modèle permet d'évaluer simultanément l'effet de plusieurs variables explicatives sur la probabilité de décès. (*Annexe IV*)

Dans un premier temps, nous avons créé une variable binaire DEATH_bin dans notre jeu de données, codée en 0 pour les patients non décédés et 1 pour les patients décédés, afin de pouvoir appliquer le modèle logistique.

Le choix des variables incluses dans le modèle initial (modele_full) s'est basé sur les résultats des tests statistiques précédents ainsi que sur leur pertinence clinique. Nous avons donc retenu l'âge (AGE), la présence d'antécédents cardiovasculaires (CARD), la pathologie infectieuse (SEPS), et deux scores cliniques (APS1 et SCOMA1), qui ont montré un lien potentiel avec la mortalité. Les variables choisies combinent des facteurs démographiques, des antécédents médicaux et des mesures cliniques synthétiques, ce qui permet de capturer différents aspects pouvant influencer le décès.

Pour optimiser ce modèle, nous avons appliqué une sélection pas à pas automatique (step), qui élimine ou conserve les variables en fonction du critère d'AIC (Akaike Information Criterion). Cette procédure vise à simplifier le modèle tout en conservant sa qualité d'ajustement.

Étape	Variables dans le modèle	Df supprimée	Deviance	AIC
Initiale	AGE + CARD + SEPS + APS1 + SCOMA1	-	5945.3	5957.3
Suppression CARD	AGE + SEPS + APS1 + SCOMA1	1	5945.4	5955.4
Suppression SEPS	AGE + CARD + APS1 + SCOMA1 (non retenu)	1	5952.8	5962.8
Suppression APS1	AGE + CARD + SEPS + SCOMA1 (non retenu)	1	5972.2	5982.2
Suppression SCOMA1	AGE + CARD + SEPS + APS1 (non retenu)	1	5999.1	6009.1
Suppression AGE	CARD + SEPS + APS1 + SCOMA1 (non retenu)	1	6154.8	6164.8

Tableau de sélection du modèle :

Ce tableau de sélection montre les AIC et les variables supprimées/ajoutées à chaque étape. Il montre que le modèle initial incluant toutes les variables avait un AIC de 5957.3. En testant la suppression de chaque variable, seule la suppression de CARD permet de réduire l'AIC (5955.4), ce qui indique que CARD n'apporte pas d'amélioration significative au modèle. La suppression des autres variables augmente l'AIC, confirmant leur importance.

La sélection a conduit à un modèle final incluant quatre variables : l'âge, la pathologie infectieuse, et les deux scores cliniques APS1 et SCOMA1. L'antécédent cardiovasculaire (CARD) a été exclu, ce qui suggère qu'il n'apporte pas d'information significative supplémentaire dans ce modèle ajusté.

Tableau des coefficients du modèle final

Variable	Estimate	Std. Error	z value	p-value	Signification
(Intercept)	-1.4627	0.1353	-10.812	< 2e-16	*** (très significatif)
AGE	0.0277	0.0019	14.372	< 2e-16	***
SEPSYes	0.2335	0.0836	2.795	0.0052	**
APS1	0.0042	0.0009	4.615	3.94e-06	***
SCOMA1	0.0068	0.0010	6.959	3.43e-12	***

L'analyse des coefficients dans le tableau résumé montre que toutes les variables retenues ont un effet statistiquement significatif (p-values < 0.01), avec des coefficients positifs indiquant que

l'augmentation de ces variables est associée à un risque accru de décès. Par exemple, chaque année supplémentaire d'âge augmente la probabilité de mortalité, de même que la présence d'une pathologie infectieuse et l'augmentation des scores cliniques.

On peut alors en déduire que, parmi l'ensemble des variables étudiées, **l'âge, la présence d'une pathologie infectieuse (SEPS), ainsi que les scores cliniques APS1 et SCOMA1** représentent les **principaux déterminants indépendants de la mortalité en réanimation**.

CONCLUSION

Dans ce projet, nous avons étudié comment certains éléments liés à l'état de santé des patients admis en soins intensifs peuvent influencer leur risque de mortalité. L'objectif principal était de savoir quels facteurs permettent de mieux prévoir si un patient a un risque plus élevé de décéder pendant son hospitalisation.

Au début, nous avons formulé l'hypothèse que plusieurs caractéristiques médicales ou cliniques, comme l'âge, la gravité de la maladie, les antécédents médicaux (diabète, infection, problèmes rénaux ou cardiaques), ou encore certains scores (comme le score de Glasgow ou Apache), pouvaient jouer un rôle important dans ce risque. Grâce aux analyses statistiques, nous avons pu tester cette hypothèse.

Nos résultats montrent que certains éléments influencent clairement le risque de mortalité. Par exemple, un âge élevé, un score de Glasgow faible (indiquant un état de conscience altéré), la présence d'une infection et un score élevé de gravité de l'état clinique sont parmi les facteurs les plus significatifs. Ces informations peuvent être très utiles pour les médecins afin de mieux surveiller les patients les plus fragiles et adapter les soins en conséquence.

D'autres facteurs que nous pensions importants, comme les antécédents cardiaques ou rénaux, se sont révélés moins liés à la mortalité dans notre étude. Cela ne signifie pas qu'ils sont sans importance, mais que dans notre échantillon, ils n'étaient pas les plus prédictifs.

Ce projet nous a aussi permis de développer des compétences en organisation du travail en groupe, en analyse de données et en interprétation de résultats. Malgré quelques difficultés au départ, notamment dans la répartition des tâches et le choix des bons outils statistiques, nous avons su nous adapter et progresser ensemble.



Cette étude montre alors qu'il est possible, grâce à certains indicateurs cliniques simples et accessibles, d'évaluer rapidement le risque de mortalité d'un patient en soins intensifs. Cela peut améliorer la prise en charge médicale et aider à sauver des vies.

TABLE DES ILLUSTRATIONS


I : Vue d'ensemble des variables (quantitatives)


Variables	Moyenne	Ecart-type	Minimum	Q1	Médiane	Q3	Maximum
Age	61,7	16,4	18	51	64	74	102
Poids	74,4	20,6	19,5	60,3	72	85,2	209
Tension artérielle	77,4	37,7	0	49	62	113	259
Fréquence respiratoire	28,3	14	0	15	30	38	100
Fréquence cardiaque	115	41,6	0	96	124	142	250
Leucocyte	15,6	12	0	8,2	13,9	20	192
Cardiovasculaire	0,35	0,48	0	0	0	1	1
Infectieux	0,18	0,38	0	0	0	0	1
Atteinte pulmonaire	0,19	0,39	0	0	0	0	1
Atteinte rénale	0,05	0,21	0	0	0	0	1
Immunosuppression	0,28	0,45	0	0	0	1	1
Survie à 2 mois	0,6	0,2	0	0,48	0,63	0,75	0,96
Score Apache	60	44,9	3	42	54	69	499
Score Glasgow	22,2	36,6	0	0	0	41	299
Décès	0,66	0,48	0	0	1	1	1

II : Analyse univariée



Répartition de la fréquence cardiaque





III : Tests statistiques : Variables qualitatives

Variable	Test statistique	Valeur du test	df	p-value
CARD	Chi² de Pearson	1.894	1	0.169
SEPS	Chi² de Pearson	5.557	1	0.018
CHRPULHX	Chi² de Pearson	4.387	1	0.036
RENALHX	Chi² de Pearson	2.312	1	0.128
IMMUNHX	Test exact de Fisher	—	—	0.004

IV : Tests statistiques : Variables quantitatives

Variable	Moyenne (Vivant)	Moyenne (Décédé)	t	p-value	IC 95 % Diff. Moy.
SCOMA1	17.03	24.92	-7.39	1.75e-13	[-9.99 ; -5.80]
SURV2MD1	0.69	0.55	27.32	< 2.2e-16	[0.13 ; 0.15]
MEANBP1	82.21	74.92	6.38	2.08e-10	[5.05 ; 9.53]
RESP1	28.19	28.30	-0.25	0.80	[-0.92 ; 0.71]
HRT1	116.48	114.71	1.44	0.15	[-0.63 ; 4.16]
WBLC1	15.27	15.78	-1.56	0.12	[-1.14 ; 0.13]
AGE	57.08	64.16	-14.10	< 2.2e-16	[-8.07 ; -6.10]

ANNEXE

Cette annexe fournit un aperçu du script R ayant servi à la mise en œuvre des différentes étapes de notre analyse.

I : Statistiques descriptives rapides : Programme R

```

12 #STATISTIQUE DESCRIPTIVES RAPIDES
13 skim(datafinal)
14 summary(datafinal)
15 #Analyse univariée
16 # DEATH
17 ggplot(data = datafinal, aes(x = factor(DEATH))) +
18   geom_bar(aes(y = after_stat(prop), group = 1), fill = "#D8A48F", width = 0.6) +
19   scale_x_discrete(labels = c("0" = "Non décédés", "1" = "Décédés")) +
20   scale_y_continuous(labels = scales::percent_format(accuracy = 1)) +
21   labs(
22     title = "Répartition des patients décédés durant le suivi",
23     x = "Patients décédés",
24     y = "Fréquence"
25   ) +
26   theme_minimal(base_size = 13) +
27   theme(
28     plot.title = element_text(face = "bold", hjust = 0.5),
29     axis.title.x = element_text(margin = margin(t = 10)),
30     axis.title.y = element_text(margin = margin(r = 10))
31   )
32 # SWANG1 (Right Heart Catheterization)
33 ggplot(data = datafinal, aes(x = factor(SWANG1)))+
34   geom_bar(aes(y = after_stat(prop), group = 1), fill = "burlywood4") +
35   labs(title = "Répartition des patients qui ont subi un catheterization",
36     x = "Patients catheterisés",
37     y = "Fréquence")
38 # Age
39 hist(datafinal$AGE, breaks = 40, prob = TRUE,
40   main = "Distribution de l'âge des patients",
41   xlab = "Age", ylab = "Densité",
42   col = "lightgray", border = "white")
43 #APS1
44 datafinal2 <- datafinal %>%
45   filter(APS1 >= 0 & APS1 <= 299) %>%
46   mutate(APS1_class = case_when(
47     APS1 >= 0 & APS1 < 30 ~ "[0-29]",
48     APS1 >= 30 & APS1 < 60 ~ "[30-59]",
49     APS1 >= 60 & APS1 < 90 ~ "[60-89]",
50     APS1 >= 90 & APS1 < 120 ~ "[90-119]",
51     APS1 >= 120 & APS1 < 150 ~ "[120-149]",
52     APS1 >= 150 & APS1 < 180 ~ "[150-179]",
53     APS1 >= 180 & APS1 < 210 ~ "[180-209]",
54     APS1 >= 210 & APS1 < 240 ~ "[210-239]",
55     APS1 >= 240 & APS1 < 270 ~ "[240-269]",
56     APS1 >= 270 & APS1 <= 299 ~ "[270-299]"
57   ))
58 datafinal2$APS1_class <- factor(datafinal2$APS1_class,
59   levels = c("[0-29]", "[30-59]", "[60-89]", "[90-119]",
60     "[120-149]", "[150-179]", "[180-209]", "[210-239]",
61     "[240-269]", "[270-299]"))

```

```

62
63 ggplot(data = datafinal2, aes(x = APS1_class)) +
64   geom_bar(aes(y = after_stat(prop), group = 1), fill = "#8FBC8F", width = 0.6) +
65   scale_y_continuous(labels = percent_format(accuracy = 1)) +
66   labs(
67     title = "Répartition des patients selon le score de gravité à l'admission",
68     x = "Score de gravité APS1",
69     y = "Fréquence"
70   ) +
71   theme_minimal(base_size = 13) +
72   theme(
73     plot.title = element_text(face = "bold", hjust = 0.5),
74     axis.title.x = element_text(margin = margin(t = 10)),
75     axis.title.y = element_text(margin = margin(r = 10)),
76     axis.text.x = element_text(size = 11)
77   )
78 #SCOMA
79 datafinal1 <- datafinal %>%
80   filter(SCOMA1 >= 0 & SCOMA1 <= 100) %>%
81   mutate(SCOMA1_class = case_when(
82     SCOMA1 >= 0 & SCOMA1 < 10 ~ "[0-9]",
83     SCOMA1 >= 10 & SCOMA1 < 20 ~ "[10-19]",
84     SCOMA1 >= 20 & SCOMA1 < 30 ~ "[20-29]",
85     SCOMA1 >= 30 & SCOMA1 < 40 ~ "[30-39]",
86     SCOMA1 >= 40 & SCOMA1 < 50 ~ "[40-49]",
87     SCOMA1 >= 50 & SCOMA1 < 60 ~ "[50-59]",
88     SCOMA1 >= 60 & SCOMA1 < 70 ~ "[60-69]",
89     SCOMA1 >= 70 & SCOMA1 < 80 ~ "[70-79]",
90     SCOMA1 >= 80 & SCOMA1 < 90 ~ "[80-89]",
91     SCOMA1 >= 90 & SCOMA1 <= 100 ~ "[90-100]"
92   ))
93 ggplot(data = datafinal1, aes(x = SCOMA1_class)) +
94   geom_bar(aes(y = after_stat(prop), group = 1), fill = "burlywood4") +
95   labs(title = "Répartition de l'état neurologique des patients",
96     x = "Classe de score SCOMA1",
97     y = "Fréquence") +
98   theme_minimal()
99 #Fréquence cardiaque
100 boxplot(datafinal$HRT1, main = "Répartition de la fréquence cardiaque",
101   ylab = "BPM", col = "lightcoral")
102 #Leucocyte(WBLC1)
103 boxplot(datafinal$WBLC1, main = "Boxplot des leucocytes",
104   ylab = "Nombre de leucocytes", col = "wheat")
105

```

II : Analyse bivariée : Aperçu du Programme R

```

109 # Cardiovasculaire
110 ggplot(data = datafinal, aes(x = factor(CARD), fill = factor(DEATH))) +
111   geom_bar(position = "fill", color = "white", width = 0.6) +
112   scale_fill_manual(
113     values = c("No" = "#66c2a5", "Yes" = "#fc8d62"),
114     labels = c("No" = "Vivant", "Yes" = "Décédé")
115   ) +
116   scale_x_discrete(labels = c("0" = "Absence", "1" = "Présence")) +
117   scale_y_continuous(labels = scales::percent_format(accuracy = 1)) +
118   labs(
119     title = "Décès selon la présence de maladie cardiovasculaire",
120     x = "Maladie cardiovasculaire",
121     y = "Fréquence",
122     fill = "Statut vital"
123   ) +
124   theme_minimal(base_size = 13) +
125   theme(
126     plot.title = element_text(face = "bold", hjust = 0.5),
127     axis.title.x = element_text(margin = margin(t = 10)),
128     axis.title.y = element_text(margin = margin(r = 10)),
129     legend.position = "right"
130   )
131
132 # Infectieux
133 ggplot(data = datafinal, aes(x = factor(SEPS), fill = factor(DEATH))) +
134   geom_bar(position = "fill", color = "white", width = 0.6) +
135   scale_fill_manual(
136     values = c("No" = "#66c2a5", "Yes" = "#fc8d62"),
137     labels = c("No" = "Vivant", "Yes" = "Décédé")
138   ) +
139   scale_x_discrete(labels = c("0" = "Absence", "1" = "Présence")) +
140   scale_y_continuous(labels = scales::percent_format(accuracy = 1)) +
141   labs(
142     title = "Décès selon la présence d'infection (SEPS)",
143     x = "Infection (SEPS)",
144     y = "Fréquence",
145     fill = "Statut vital"
146   ) +
147   theme_minimal(base_size = 13) +
148   theme(
149     plot.title = element_text(face = "bold", hjust = 0.5),
150     axis.title.x = element_text(margin = margin(t = 10)),
151     axis.title.y = element_text(margin = margin(r = 10)),
152     legend.position = "right"
153   )
154

```

III : Tests statistiques

```

554 #Test statistiques
555 #VARIABLES QUALITATIVES
556 #Chi²
557 chisq.test(table(datafinal$DEATH, datafinal$CARD))
558 #Il n'y a pas de lien statistiquement significatif entre la présence d'un diagnostic cardiovasculaire (CARD) et la mortalité
559
560 chisq.test(table(datafinal$DEATH, datafinal$SEPS))
561 #Les patients atteints d'infection présentent un risque de décès significativement différent.
562
563 chisq.test(table(datafinal$DEATH, datafinal$CHRPULHX))
564 #L'atteinte pulmonaire semble influencer significativement la mortalité.
565
566 chisq.test(table(datafinal$DEATH, datafinal$RENALHX))
567 #L'atteinte rénale ne semble pas liée de manière significative à la mortalité dans cet échantillon.
568
569 #fisher
570 fisher.test(table(datafinal$DEATH, datafinal$IMMUNHX))
571 #Il existe une association statistiquement significative entre IMMUNHX et la mortalité (DEATH).
572
573 #VARIABLES QUANTI QUALI
574
575 t.test(APS1 ~ DEATH, data = datafinal) # score APS
576 #Le test de Student indique une différence significative du score APS1 entre les patients décédés et non décédés
577
578 t.test(SCOMA1 ~ DEATH, data = datafinal) # score Glasgow
579 #Une différence très significative est observée sur le score SCOMA1.
580
581 t.test(SURV2MD1 ~ DEATH, data = datafinal) # probabilité survie
582 #Le test t montre une forte différence significative de la probabilité estimée de survie
583
584 t.test(MEANBP1 ~ DEATH, data = datafinal) # pression moyenne
585 #Une différence significative est notée sur la pression moyenne
586
587 t.test(RESPI ~ DEATH, data = datafinal) # fréquence respi
588 #Aucune différence significative n'est observée pour la fréquence respiratoire
589
590 t.test(HRT1 ~ DEATH, data = datafinal) # fréquence cardiaque
591 #Le test ne montre pas de différence significative
592
593 t.test(WBLC1 ~ DEATH, data = datafinal) # leucocytes
594 #Aucune différence significative sur les leucocytes
595
596 t.test(AGE ~ DEATH, data = datafinal)
597 #Le test indique une différence hautement significative
598

```

IV : Modèle logistique

```

599 #Modèle logistique
600 datafinal$DEATH_bin <- ifelse(datafinal$DEATH == "Yes", 1, 0)
601 modele_full <- glm(DEATH_bin ~ AGE + CARD + SEPS + APS1 + SCOMA1,
602                   data = datafinal,
603                   family = binomial)
604 modele_step <- step(modele_full, direction = "both")
605 summary(modele_step)
606

```