

SAE ESTIMATION

INTRODUCTION ET MODELISATION DES DONNEES

Ce rapport porte sur l'étude d'un jeu de données nommé *Star39552balanced.csv*, qui contient 39 552 étoiles (taille de la population $N = 39\,552$). Chaque étoile est décrite par plusieurs variables, dont ***Plx***, la distance entre l'étoile et la Terre, exprimée en années-lumière.

On note $\mu = 7.117378$ la distance moyenne théorique entre une étoile et la Terre dans cette population, et σ^2 la variance associée. Aucune information supplémentaire n'est disponible sur la loi suivie par la variable *Plx*. Une valeur de référence $\mu_0 = 7$ est proposée, que l'on cherchera à vérifier à partir des échantillons.

Pour mieux comprendre cette variable, deux échantillons ont été extraits de cette population :

- un échantillon de taille $n_1 = 30$, nommé *plx_30_1.csv*,
- un plus grand échantillon de taille $n_2 = 100$, nommé *plx_100_1.csv*.

Nous sommes dans le cadre de grands échantillons (de loi quelconque), avec variance inconnue σ^2 .

L'objectif est d'analyser la variable *Plx* à partir de ces deux échantillons, d'estimer les caractéristiques de la population, et d'étudier l'influence de la taille de l'échantillon sur la qualité des résultats.

Ce rapport s'appuie sur des sorties R (résultats d'analyses statistiques) qui seront présentées et interprétées tout au long de l'étude.


1) ECHANTILLON DE TAILLE n1 = 30

Moyenne théorique de la plx : $\mu = 7.117378$

Moyenne sur l'échantillon (valeur estimée de μ) : $\bar{X}_{30} = 6.093333$

a) Statistiques descriptives

Répartition de la variable Plx sur l'échantillon



Résumé statistique sur l'échantillon (Sorties R)

Min: 0.060; 1st Qu: 2.397; Median : 4.100 ; Mean : 6.093 ;3rd Qu: 8.700 Max :32.100

Interprétation : Le boxplot et l'histogramme montrent que la plupart des distances entre les étoiles et la Terre sont regroupées entre 2.4 et 8.7. La médiane à 4.1 signifie que la moitié des étoiles sont plus proches que cette distance. La moyenne, plus élevée à 6.093, est tirée vers le haut par deux valeurs extrêmes très importantes, jusqu'à 32.1. Ces deux valeurs extrêmes apparaissent clairement sur le boxplot comme des points isolés, ce qui indique qu'elles sont loins du reste des données. L'histogramme confirme que ces grandes distances sont rares comparées aux petites.

On peut en déduire que la majorité des étoiles sont proches, mais deux étoiles sont beaucoup plus éloignées, ce qui augmente la moyenne et montre que les distances sont assez dispersées avec quelques valeurs très élevées.

Variance : 41.66344

Interprétation : La variance de 41.66 dans l'échantillon montre que les distances des étoiles sont très variées, avec des étoiles proches comme des étoiles beaucoup plus éloignées.

b) Intervalles de confiance

i) Au niveau de confiance $1 - \alpha_1 = 95\%$ de μ

```
> # Construction IC bilatéral de Mu au seuil 1-alpha=95%
> alpha1=0.05
> qt((1-(alpha1/2)),n1-1)
[1] 2.04523
> Ecart=qt((1-(alpha1/2)),n1-1)*sigma30/sqrt(n1)
> Ecart
[1] 2.410233
> a=Xbar30-Ecart # La borne gauche
> a
[1] 3.6831
> b=Xbar30+Ecart # La borne droite
> b
[1] 8.503566
> print(paste("Xbar=",Xbar30,"IC",100*(1-alpha1),"%[",a,"-",b,"]"))
[1] "Xbar= 6.09333333333333 IC 95 %[ 3.68310030818869 - 8.50356635847798 ]"
```

Interprétation : On s'appuie sur la valeur estimée $\bar{X}_{30}$ de la moyenne μ . L'**intervalle de confiance asymptotique** de niveau 95% pour μ s'écrit :

IC = [$\bar{X}_{30}$ -Ecart ; $\bar{X}_{30}$ +Ecart] où $t(n_1-1) = 2.04523$ est le quantile d'ordre $1-\alpha_1/2$ de la loi de Student à $n_1-1 = 29$ degrés de liberté. D'après les données de l'échantillon, l'estimation par intervalle donne : **IC 95% = [3.6831 ; 8.5036]**. Cet intervalle contient la moyenne théorique $\mu = 7.117378$, ce qui signifie qu'**avec un niveau de confiance de 95%, on peut estimer que la vraie moyenne de la population se trouve dans cet intervalle.**

ii) Au niveau de confiance $1 - \alpha_2 = 99\%$ de μ

```
> alpha2=0.01
> qt((1-(alpha2/2)),n1-1)
[1] 2.756386
> Ecart=qt((1-(alpha2/2)),n1-1)*sigma30/sqrt(n1)
> Ecart
[1] 3.248306
> c=Xbar30-Ecart # La borne gauche
> c
[1] 2.845027
> d=Xbar30+Ecart # La borne droite
> d
[1] 9.34164
> print(paste("Xbar=",Xbar30,"IC",100*(1-alpha2),"%[",c,"-",d,"]"))
[1] "Xbar= 6.09333333333333 IC 99 %[ 2.84502703158113 - 9.34163963508554 ]"
```

Interprétation : On s'appuie aussi sur la valeur estimée $\bar{X}_{30}$ de la moyenne μ . D'après les données de l'échantillon, l'estimation par intervalle donne : **IC 99% = [2.8450 ; 9.3416]**. Cet **intervalle contient la moyenne théorique** $\mu = 7.117378$, ce qui signifie qu'**avec un niveau de confiance de 99 %, on peut estimer que la vraie moyenne de la population se trouve dans cet intervalle.** Cet intervalle est plus large car un niveau de confiance plus élevé signifie que l'on veut être plus sûr de contenir la vraie moyenne. On peut en déduire que plus le niveau de confiance augmente, plus l'intervalle est large.

c) Test de comparaison de moyennes avec les quantiles et p-valeurs ($H_0 : \mu=7$)

Risque $\alpha_1 = 5\%$

```
> # Statistique de Test H0: Mu=Muo
> mutheo=7 #Mu0
> t=sqrt(n1)*(Xbar30-mutheo)/sigma30
> t
[1] -0.7693619
> # quantile du test
> qt((1-(alpha1/2)),n1-1)
[1] 2.04523
> # p-valeur du test
> pval=2*(pt(abs(t),n1-1,lower.tail = FALSE))
> pval
[1] 0.4478999
> # Resultat du Test Mu=Muo
> print(paste(" T=",t,"ddl=",n1-1," p-valeur=",pval))
[1] " T= -0.76936193424245 ddl= 29 p-valeur= 0.44789993614679"
```

Statistique de
test : $T = -0.7694$
Degrés de liberté
= 29
Quantile
critique = 2.0452
p-valeur = 0.448

Interprétation : Nous réalisons un **test d'hypothèse au niveau $\alpha_1 = 5\%$** pour vérifier si la moyenne μ de la distance entre les étoiles et la Terre est égale à 7, en posant $H_0 : \mu = 7$ contre $H_1 : \mu \neq 7$. La **statistique de test** est calculée à partir de l'échantillon de taille 30 en utilisant la loi de Student, puisque la variance de la population est inconnue. Sous H_0 , cette statistique suit une loi de Student à 29 degrés de liberté. La **règle de décision est de rejeter H_0** si la valeur absolue de la statistique est supérieure au quantile critique 2.0452. Ici, la valeur absolue de la **statistique** calculée est **0.7694**, inférieure à ce seuil, et la **p-valeur** associée est de **0.448**, bien supérieure au niveau de signification de 0.05. Par conséquent, **on ne rejette pas H_0 , ce qui signifie qu'avec un risque d'erreur de 5%, il n'y a pas de preuve statistique que la moyenne de la distance diffère de 7.** Autrement dit, la distance moyenne estimée à partir de l'échantillon ne s'écarte pas significativement de la valeur de référence.

Risque $\alpha_2 = 1\%$

```
> # Statistique de Test H0: Mu=Muo
> mutheo=7 #Mu0
> t=sqrt(n1)*(Xbar30-mutheo)/sigma30
> t
[1] -0.7693619
> # quantile du test
> qt((1-(alpha2/2)),n1-1)
[1] 2.756386
> # p-valeur du test
> pval=2*(pt(abs(t),n1-1,lower.tail = FALSE))
> pval
[1] 0.4478999
> # Resultat du Test Mu=Muo
> print(paste(" T=",t,"ddl=",n1-1," p-valeur=",pval))
[1] " T= -0.76936193424245 ddl= 29 p-valeur= 0.44789993614679"
```

Statistique de
test : $T = -0.7694$
Degrés de liberté
= 29
Quantile
critique = 2.7564
p-valeur = 0.448

Interprétation : Nous réalisons également un **test d'hypothèse au niveau $\alpha_2 = 1\%$** pour vérifier si la moyenne μ de la distance entre les étoiles et la Terre est égale à 7. Ici, la règle de décision est aussi de rejeter H_0 si la valeur absolue de la statistique est supérieure au **quantile critique 2.7564**. Ici, la statistique calculée est la même que celle au niveau α_1 , inférieure à ce seuil, et la p-valeur associée est de 0.448, bien supérieure au niveau de signification de 0.01. Par conséquent, **on ne rejette pas**

non plus H_0 , ce qui signifie qu'avec un risque d'erreur de 1%, il n'y a pas de preuve statistique que la moyenne de la distance diffère de 7. Autrement dit, comme au niveau de risque 5%, la distance moyenne estimée à partir de l'échantillon ne s'écarte pas significativement de la valeur de référence.

d) Test de comparaison des moyennes avec les intervalles de confiance

i) Au niveau de confiance $1 - \alpha_1 = 95\%$

On rappelle l'intervalle de confiance à 95 % : [3.6831 ; 8.5036]

Interprétation : On a démontré que $P(\mu_0 \in [3.6831 ; 8.5036]) \approx 0.95$ et par complémentarité, $P(\mu_0 \notin [3.6831 ; 8.5036]) \approx 0.05$. Ici, la distance moyenne ne diffère pas de la valeur annoncée, $\mu_0 = 7 \in [3.6831 ; 8.5036]$. On peut donc dire que la distance moyenne entre l'étoile et la Terre ne diffère pas significativement avec la valeur annoncée avec une probabilité à peu près égale à 0.05 de se tromper. **On ne rejette donc pas l'hypothèse $H_0 : \mu_0 = 7$.**

ii) Au niveau de confiance $1 - \alpha_2 = 99\%$

On rappelle l'intervalle de confiance à 99 % : [2.8450 ; 9.3416]

Interprétation : On a démontré que $P(\mu_0 \in [2.8450 ; 9.3416]) \approx 0.99$ et par complémentarité, $P(\mu_0 \notin [2.8450 ; 9.3416]) \approx 0.01$. Ici, la distance moyenne ne diffère pas de la valeur annoncée, $\mu_0 = 7 \in [2.8450 ; 9.3416]$. On peut donc dire que la distance moyenne entre l'étoile et la Terre ne diffère pas significativement avec la valeur annoncée avec une probabilité à peu près égale à 0.01 de se tromper. **On ne rejette donc pas non plus l'hypothèse $H_0 : \mu_0 = 7$.**

e) Tests de moyenne avec fonction R intégrée

Risque $\alpha_1 = 5\%$

```
> t.test(ech30$Plx,mu=7, conf.level=1-alpha1)
```

One Sample t-test

```
data: ech30$Plx
t = -0.76936, df = 29, p-value = 0.4479
alternative hypothesis: true mean is not equal to 7
95 percent confidence interval:
 3.683100 8.503566
sample estimates:
mean of x
 6.093333
```

Risque $\alpha_2 = 1\%$

```
> t.test(ech30$Plx,mu=7, conf.level=1-alpha2)
```

One Sample t-test


```
data: ech30$Plx
t = -0.76936, df = 29, p-value = 0.4479
alternative hypothesis: true mean is not equal to 7
99 percent confidence interval:
 2.845027 9.341640
sample estimates:
mean of x
 6.093333
```

Ces deux tests confirment les résultats précédents : la p-valeur élevée et les intervalles de confiance contenant 7 montrent qu'on ne rejette pas l'hypothèse que la moyenne soit égale à 7.

f) Visualisation du test t : densité, statistique observée et zones de rejet


Les graphiques présentent la **densité de la loi de Student de la statistique de test t sous l'hypothèse nulle H_0** . La **courbe noire** illustre la **distribution théorique de t lorsque H_0 est vraie**, c'est-à-dire que la moyenne de la population est égale à la valeur testée (ici 7). **Les deux lignes rouges** verticales correspondent aux **quantiles critiques** de cette loi, qui délimitent les zones de rejet de H_0 pour les niveaux de risque $\alpha_1=5\%$ et $\alpha_2=1\%$. Les valeurs qui ne sont pas encadrées entre les deux lignes rouges les valeurs extrêmes de la statistique qui conduiraient à rejeter l'hypothèse nulle. La **ligne bleue** indique la **valeur observée de la statistique de test calculée** à partir des données.

i) Au risque $\alpha_1 = 5\%$



Interprétation : On observe que la valeur de t se situe bien à l'intérieur des quantiles rouges, dans la zone de non-rejet. Cela signifie que, au seuil de 5%, la statistique n'est pas suffisamment extrême pour rejeter l'hypothèse nulle.

ii) Au risque $\alpha_2 = 1\%$



Interprétation : La valeur observée reste également à l'intérieur des bornes critiques. Cet intervalle est plus large, ce qui rend la zone de non-rejet plus étendue, confirmant ainsi qu'à ce niveau plus rigoureux, il n'y a toujours pas de preuve statistique suffisante pour rejeter H_0 .

g) Conclusion sur l'échantillon de taille $n_1 = 30$



L'analyse de l'échantillon de taille $n_1 = 30$ vise à évaluer si la moyenne réelle μ de la distance entre les étoiles et la Terre est différente de la valeur de référence $\mu_0 = 7$. La moyenne observée sur l'échantillon est $\bar{X}_{30} = 6.093$, ce qui est inférieur à μ_0 , mais cette différence n'est pas statistiquement significative. En effet, les intervalles de confiance à 95 % et à 99 % contiennent la valeur $\mu_0 = 7$, ce qui signifie que, compte tenu de la variabilité des données et de la taille de l'échantillon, on ne peut pas exclure que la vraie moyenne soit égale à 7. De plus, le test de Student donne une statistique de test $t = -0.7694$, inférieure aux seuils critiques aux niveaux 5 % et 1 %, avec une p-valeur de 0.448, largement supérieure à ces seuils. Par conséquent, on ne rejette pas l'hypothèse nulle $H_0 : \mu_0 = 7$. Cela signifie que, avec un risque d'erreur de 5 % ou 1 %, les données de l'échantillon ne permettent pas de conclure que la moyenne réelle diffère de 7.

2) ECHANTILLON TAILLE n2 = 100

Moyenne sur l'échantillon (valeur estimée de μ) : $\bar{X}_{100} = 6.5173$

a) Statistiques descriptives

Répartition de la variable Plx sur l'échantillon



Résumé statistique (Sorties R)

Min :-0.190 ; 1st Qu: 2.853 ; Median : 4.280 ; Mean : 6.517 ; 3rd Qu: 8.620 ;
Max:24.750

Interprétation : Le boxplot met en évidence plusieurs valeurs extrêmes, visibles sous forme de points isolés au-dessus du troisième quartile (8.62), ce qui traduit une forte variabilité des données. On remarque aussi que l'écart entre la médiane (4.28) et le troisième quartile est plus grand que celui entre la médiane et le premier quartile, indiquant une distribution asymétrique vers la droite. L'histogramme confirme cette observation en montrant que la majorité des données se concentrent autour de la médiane, mais avec une longue queue vers des valeurs élevées allant jusqu'à 24.75. On compte au total 11 valeurs extrêmes.

On peut en déduire que ces valeurs extrêmes augmentent la dispersion globale et créent une asymétrie dans la distribution. Par conséquent, la moyenne est influencée à la hausse par ces observations élevées, tandis que la médiane reste un indicateur plus représentatif de la tendance centrale réelle des données.

Variance : 34.0734

Interprétation : La variance est plus faible que dans l'échantillon de taille 30 (41.66344), ce qui signifie que les données sont globalement moins dispersées. Même si quelques valeurs extrêmes augmentent un peu cette variabilité, la plupart des observations restent plus proches de la moyenne, ce qui réduit la variance globale par rapport à l'échantillon précédent.

b) Intervalles de confiance

i) Au niveau de confiance $1 - \alpha_1 = 95\%$ de μ

```
> alpha1=0.05
> qt((1-(alpha1/2)),n2-1)
[1] 1.984217
> Ecart=qt((1-(alpha1/2)),n2-1)*sigma100/sqrt(n2)
> Ecart
[1] 1.158236
> e=Xbar100-Ecart # La borne gauche
> e
[1] 5.359064
> f=Xbar100+Ecart # La borne droite
> f
[1] 7.675536
> print(paste("Xbar=",Xbar100,"IC",100*(1-alpha1),"%[",e,"-",f,"]"))
[1] "Xbar= 6.5173 IC 95 %[ 5.35906441880558 - 7.67553558119442 ]"
```

Interprétation : On s'appuie sur la valeur estimée $\bar{X}_{100}$ de la moyenne μ . L'intervalle de confiance asymptotique de niveau 95 % pour μ s'écrit :

IC = $[\bar{X}_{100} - \text{Ecart} ; \bar{X}_{100} + \text{Ecart}]$ où $t(n_2-1) = 1.984217$ est le quantile d'ordre $1-\alpha_1/2$ de la loi de Student à 99 degrés de liberté. D'après les données de l'échantillon, l'estimation par intervalle donne : **IC 95% = [5.3591 ; 7.6755]**. Cet intervalle contient la moyenne théorique $\mu=7.117378$, ce qui signifie **qu'avec un niveau de confiance de 95 %, on peut estimer que la vraie moyenne de la population se trouve dans cet intervalle**. De plus, cet intervalle est plus étroit que celui obtenu avec l'échantillon de taille 30, indiquant une estimation plus précise de la moyenne.

ii) Au niveau de confiance $1 - \alpha_2 = 99\%$ de μ

```
> alpha2=0.01
> qt((1-(alpha2/2)),n2-1)
[1] 2.626405
> Ecart=qt((1-(alpha2/2)),n2-1)*sigma100/sqrt(n2)
> Ecart
[1] 1.533097
> g=Xbar100-Ecart # La borne gauche
> g
[1] 4.984203
> h=Xbar100+Ecart # La borne droite
> h
[1] 8.050397
> print(paste("Xbar=",Xbar100,"IC",100*(1-alpha2),"%[",g,"-",h,"]"))
[1] "Xbar= 6.5173 IC 99 %[ 4.98420340548007 - 8.05039659451993 ]"
```

Interprétation : On s'appuie aussi sur la valeur estimée $\bar{X}_{100}$ de la moyenne μ . D'après les données de l'échantillon, l'estimation par intervalle donne : **IC 99% = [4.9842 ; 8.0504]**. Cet intervalle contient la moyenne théorique $\mu=7.117378$, ce qui signifie **qu'avec un niveau de confiance de 99 %, on peut estimer que la vraie moyenne de la population se trouve dans cet intervalle**. Cet intervalle est plus large car un niveau de confiance plus élevé signifie que l'on veut être plus sûr de contenir la vraie moyenne. Donc plus le niveau de confiance augmente, plus l'intervalle est large.

c) Test de comparaison de moyennes avec les quantiles et p-valeurs ($H_0 : \mu_0 = 7$)

Risque $\alpha_1 = 5\%$

```
> mutheo=7 #Mu0
> t=sqrt(n2)*(Xbar100-mutheo)/sigma100
> t
[1] -0.8269315
> # quantile du test
> qt((1-(alpha1/2)),n2-1)
[1] 1.984217
> # p-valeur du test
> pval=2*(pt(abs(t),n2-1,lower.tail = FALSE))
> pval
[1] 0.4102646
> # Resultat du Test Mu=Mu0
> print(paste(" T=",t,"ddl=",n2-1," p-valeur=",pval))
[1] " T= -0.826931531099278 ddl= 99 p-valeur= 0.410264564477076"
```

Statistique de test : $T = -0.8269$
Degrés de liberté = 99
Quantile critique = 1.9842
p-valeur = 0.4103

Interprétation : On pose $H_0 : \mu_0 = 7$ contre $H_1 : \mu \neq 7$. La statistique de test est calculée à partir de l'échantillon de taille 100 en utilisant la loi de Student, puisque la variance de la population est inconnue. Sous H_0 , cette statistique suit une loi de Student à 99 degrés de liberté. La **règle de décision** est de rejeter H_0 si la valeur absolue de la statistique est supérieure au quantile critique 1.9842. Ici, la valeur absolue de la **statistique** calculée est **0.8269**, **inférieure à ce seuil**, et la **p-valeur** associée est de **0.4103**, bien **supérieure au niveau de signification de 0.05**. Par conséquent, **on ne rejette pas H_0 , ce qui signifie qu'avec un risque d'erreur de 5%, il n'y a pas de preuve statistique que la moyenne de la distance diffère de 7.** Autrement dit, la distance moyenne estimée à partir de l'échantillon ne s'écarte pas significativement de la valeur de référence comme pour l'échantillon de taille $n_1 = 30$.

Risque $\alpha_2 = 1\%$

```
> mutheo=7 #Mu0
> t=sqrt(n2)*(Xbar100-mutheo)/sigma100
> t
[1] -0.8269315
> # quantile du test
> qt((1-(alpha2/2)),n2-1)
[1] 2.626405
> # p-valeur du test
> pval=2*(pt(abs(t),n2-1,lower.tail = FALSE))
> pval
[1] 0.4102646
> # Resultat du Test Mu=Mu0
> print(paste(" T=",t,"ddl=",n2-1," p-valeur=",pval))
[1] " T= -0.826931531099278 ddl= 99 p-valeur= 0.410264564477076"
```

Statistique de test : $T = -0.8269$
Degrés de liberté = 99
Quantile critique = 2.6264
p-valeur = 0.4103

Interprétation : Nous réalisons également un test d'hypothèse au niveau $\alpha_2 = 1\%$ pour vérifier si la moyenne μ de la distance entre les étoiles et la Terre est égale à 7. Ici, la règle de décision est aussi de rejeter H_0 si la valeur absolue de la statistique est supérieure au quantile critique **2.6264**. Ici, la valeur absolue de la **statistique** calculée est la même que celle au niveau α_1 , **inférieure à ce seuil**, et la **p-valeur** associée est de **0.4103**, bien **supérieure au niveau de signification de 0.01**. Par conséquent, **on ne rejette pas non plus H_0 , ce qui signifie qu'avec un risque d'erreur de 1%, il n'y a pas de preuve statistique que la moyenne de la distance diffère de 7.**

Autrement dit, comme au niveau de risque 5%, la distance moyenne estimée à partir de l'échantillon ne s'écarte pas significativement de la valeur de référence.

d) Test de comparaison des moyennes avec les intervalles de confiance

i) Au niveau de confiance $1 - \alpha_1 = 95\%$

On rappelle l'intervalle de confiance à 95 % : [5.35901 ; 7.6755]

Interprétation : On a démontré que $P(\mu_0 \in [5.35901 ; 7.6755]) \approx 0.95$ et par complémentarité, $P(\mu_0 \notin [5.35901 ; 7.6755]) \approx 0.05$. Ici, la distance moyenne ne diffère pas de la valeur annoncée, $\mu_0 = 7 \in [5.35901 ; 7.6755]$. On peut donc dire que la distance moyenne entre l'étoile et la Terre ne diffère pas significativement avec la valeur annoncée avec une probabilité à peu près égale à 0.05 de se tromper. **On ne rejette donc pas l'hypothèse $H_0 : \mu_0 = 7$.**

ii) Au niveau de confiance $1 - \alpha_2 = 99\%$

On rappelle l'intervalle de confiance à 99% : [4.9842 ; 8.0504]

Interprétation : On a démontré que $P(\mu_0 \in [4.9842 ; 8.0504]) \approx 0.99$ par complémentarité, $P(\mu_0 \notin [4.9842 ; 8.0504]) \approx 0.01$. Ici, la distance moyenne ne diffère pas de la valeur annoncée, $\mu_0 = 7 \in [4.9842 ; 8.0504]$. On peut donc dire que la distance moyenne entre l'étoile et la Terre ne diffère pas significativement avec la valeur annoncée avec une probabilité à peu près égale à 0.01 de se tromper. **On ne rejette donc pas non plus l'hypothèse $H_0 : \mu_0 = 7$.**

e) Tests de moyenne avec fonction R intégrée

Risque $\alpha_1 = 5\%$

```
> t.test(ech100$Plx,mu=7, conf.level=1-alpha1)
```

One Sample t-test

```
data: ech100$Plx
t = -0.82693, df = 99, p-value = 0.4103
alternative hypothesis: true mean is not equal to 7
95 percent confidence interval:
 5.359064 7.675536
sample estimates:
mean of x
 6.5173
```

Risque $\alpha_2 = 1\%$

```
> t.test(ech100$Plx,mu=7, conf.level=1-alpha2)
```


One Sample t-test

```
data: ech100$Plx
t = -0.82693, df = 99, p-value = 0.4103
alternative hypothesis: true mean is not equal to 7
99 percent confidence interval:
 4.984203 8.050397
sample estimates:
mean of x
 6.5173
```

Ces deux tests confirment les résultats précédents : la p-valeur élevée et les intervalles de confiance contenant 7 montrent qu'on ne rejette pas l'hypothèse que la moyenne soit égale à 7.


f) Visualisation du test t : densité, statistique observée et zones de rejet

i) au risque $\alpha_1 = 5\%$



Interprétation : On observe que la valeur de t se situe bien à l'intérieur des quantiles rouges, dans la zone de non-rejet. Cela signifie que, au seuil de 5%, la statistique n'est pas suffisamment extrême pour rejeter l'hypothèse nulle. De plus, l'écart entre ces quantiles est légèrement plus réduit que pour l'échantillon de taille $n_1 = 30$, ce qui traduit une estimation plus précise liée à la taille plus importante de l'échantillon.

ii) au risque $\alpha_2 = 1\%$



Interprétation : On remarque que la valeur de la statistique T reste bien à l'intérieur des quantiles critiques, donc dans la zone de non-rejet de H_0 . Cela confirme qu'au niveau de risque plus strict de 1 %, il n'y a pas de raison de rejeter l'hypothèse nulle.

L'écart entre les quantiles critiques est plus large qu'à 5 %, ce qui correspond à un intervalle de confiance plus large, reflétant un critère plus rigoureux. Cependant, cet intervalle est plus étroit que celui obtenu pour l'échantillon de taille 30, ce qui montre que la taille plus grande de l'échantillon permet une estimation plus précise malgré

le niveau de confiance plus élevé.

3) CONCLUSION GENERALE

Dans cette étude, nous avons analysé deux échantillons : un de taille $n_1 = 30$ et un autre de taille $n_2 = 100$. Dans les deux cas, la moyenne obtenue est un peu plus basse que la valeur théorique ($\mu = 7.117378$), mais cette différence reste trop faible pour affirmer que la moyenne réelle est différente de 7 ($\mu_0 = 7$).

Les tests statistiques réalisés avec un seuil de 5 % et de 1 % donnent tous la même conclusion : on ne rejette pas l'hypothèse que la moyenne est égale à 7. Les intervalles de confiance confirment également cela, car ils contiennent bien cette valeur.

Nous avons aussi constaté que la taille de l'échantillon influence fortement la précision des résultats. Avec 30 valeurs, les intervalles de confiance sont larges, ce qui signifie que l'estimation est incertaine. En revanche, avec 100 valeurs, les intervalles sont plus resserrés, donc l'estimation est plus précise. Un plus grand échantillon rend aussi la moyenne plus stable, car elle est moins influencée par quelques valeurs très élevées ou très faibles.

Enfin, on remarque que les intervalles de confiance à 99 % sont toujours plus larges que ceux à 95 %, ce qui est normal : plus on veut être sûr de contenir la vraie valeur, plus on élargit l'intervalle.

Nous pouvons donc retenir que, les deux échantillons donnent des résultats proches de la valeur de référence. Aucun ne permet de rejeter l'hypothèse que la moyenne est 7. Mais l'échantillon plus grand fournit des résultats plus fiables. Cela montre bien l'importance d'avoir un nombre suffisant de données et de tenir compte de la forme de la distribution dans l'analyse statistique.