

SAE

Régression sur données réelles

ÉTUDE DE LA CROISSANCE CHEZ LES 5–19 ANS

Eda BASARAN, Santatriniaina RASOLOFOMANANA, Abderaman HAÏGA

SOMMAIRE

INTRODUCTION	p.3
1. ANALYSES DESCRIPTIVES	p.3 à 5
a) Analyse univariée	p.3
b) Analyses bivariées	p.4
c) Analyse multivariée	p.5
2. AJUSTEMENT POLYNOMIAL	p.5 à 7
a) La taille des garçons en République Dominicaine	p.6
b) La taille des filles en République Dominicaine	p.6
c) La taille des garçons au Sri Lanka	p.7
d) La taille des filles au Sri Lanka	p.7
3. ANALYSE PAR CLASSE D'AGE :	
COURBES DE MEDIANE, 1ER ET 3E QUARTILE	p.8 à 10
a) La croissance des garçons en République Dominicaine	p.8
b) La croissance des filles en République Dominicaine	p.9
c) La croissance des garçons au Sri Lanka	p.9
d) La croissance des filles au Sri Lanka	p.10
CONCLUSION	p.11
ANNEXE	p.12 et 13

INTRODUCTION

Le jeu de données à analyser provient d'une étude internationale réalisée en 2020 afin de recueillir des informations sur les courbes de croissance des filles et des garçons âgés de 5 à 19 ans dans plus de 90 pays.

Notre jeu de données contient 8000 observations basées sur 2 pays : la République Dominicaine et le Sri Lanka. Pour chaque pays, nous avons 4000 observations dont 2000 à propos des filles et 2000 à propos des garçons.


Nous avons au total 4 variables : 2 variables qualitatives qui sont le pays et le sexe et 2 variables quantitatives qui sont la taille (en cm) et l'âge (en années).

L'objectif de cette étude est de décrire et modéliser les courbes de croissance (taille en fonction de l'âge) des filles et des garçons dans ces deux pays, à l'aide d'outils statistiques. Cela inclut :

- Une **analyse descriptive** des données.
- Une **modélisation des courbes** par régression polynomiale.
- La construction des **courbes de médiane, de 1ers et 3es quartiles** par tranche d'âge.
- Et enfin, une **comparaison des croissances** entre sexes et entre pays.

1. ANALYSES DESCRIPTIVES


a) Analyse univariée



Le boxplot présente la répartition des tailles des filles et des garçons des deux pays. La taille minimale est d'environ 99,6 cm, et la taille maximale atteint 181,1 cm. La médiane, qui représente la valeur centrale, est à 146,1 cm. Le premier quartile est à 127,6 cm, tandis que le troisième quartile est à 157,5 cm. La différence entre la médiane et le premier quartile est d'environ 18,6 cm, alors que la différence entre le troisième quartile et la médiane est plus faible, environ 11,4 cm. Cela montre que les tailles sont plus dispersées du côté des valeurs plus petites que du côté des tailles plus grandes. Nous pouvons donc en déduire que la distribution des tailles est légèrement déséquilibrée, avec une plus grande variation

parmi les personnes de plus petite taille.


b) Analyses bivariées



Ce boxplot représente la répartition de la taille des filles et des garçons dans les deux pays.

La médiane est de 146cm chez les filles et les garçons, le premier quartile est de 127cm chez les garçons et 126 cm chez les filles. Quant au troisième quartile, il est de 163 cm pour les garçons et 156cm pour les filles (75% des garçons ont une taille supérieure ou égale à 163cm contre 156cm pour les filles). De plus, le maximum pour les garçons est de 181 cm contre 168 pour les garçons. Nous pouvons en déduire

que les garçons sont plus grands que les filles. De plus, la taille des garçons est plus dispersée que celle des filles. En effet la différence entre le premier quartile et le troisième quartile est de 36 cm pour les garçons contre 30cm chez les filles




Ce boxplot représente la répartition de la taille des filles et des garçons au Sri Lanka et en République Dominicaine.

Au sri Lanka, la médiane atteint 143cm, le premier quartile 124cm et le troisième quartile 155cm. Le maximum est de 176cm et le minimum est de 100cm.

En République Dominicaine, la médiane atteint 151cm, le premier quartile 152cm et le troisième quartile 160cm. Le maximum est de 180cm et le minimum est de 108cm.

75% de la population ont une taille comprise entre 100 et 155 au sri Lanka. 75% de la population ont une taille comprise entre 108 et 160 en République Dominicaine. Nous pouvons en déduire qu'au sri Lanka, les individus sont plus petits.

c) Analyse multivariée



En République Dominicaine, 75% des garçons ont une taille comprise entre 109 (minimum) et 163,5 (troisième quartile). La taille maximale est de 181cm.

Au Sri Lanka, 75% des garçons ont une taille comprise entre 100 (minimum) et 160 (troisième quartile). La taille maximale est de 178cm.

En république dominicaine, 75% des filles ont une taille comprise entre 109 (minimum) et 158 (troisième quartile). La taille maximale est de 169cm.

Au Sri Lanka, 75% des filles ont une taille comprise entre 101 (minimum) et 151 (troisième quartile). La taille maximale est de 163cm. Pour les deux pays, la taille des garçons est plus dispersée que celle des filles.

Au Sri Lanka, les filles et les garçons sont de plus petites tailles que ceux en République Dominicaine.

Après avoir décrit l'évolution de la taille par des analyses descriptives, nous avons utilisé des ajustements polynomiaux pour modéliser plus précisément la croissance en fonction de l'âge.

2. AJUSTEMENT POLYNOMIAL


Pour modéliser les courbes de croissance, nous avons commencé par un ajustement linéaire, c'est-à-dire un polynôme de degré 1, en représentant la taille en fonction de l'âge. Ensuite, nous avons testé des polynômes de degrés supérieurs, afin de vérifier si un modèle plus complexe améliorerait l'ajustement. Pour cela, nous avons utilisé la fonction **lm()** dans R pour effectuer ces régressions polynomiales.

Pour comparer ces modèles, nous avons utilisé le critère d'information d'Akaike (AIC). À chaque degré testé, nous avons calculé l'AIC du modèle correspondant à l'aide de la fonction **AIC()** dans R. Ce critère permet d'évaluer la qualité de l'ajustement tout en pénalisant les modèles trop complexes.

Dès que nous avons constaté une augmentation de l'AIC, nous avons retenu le modèle correspondant au plus petit AIC, c'est-à-dire celui qui offre le meilleur compromis entre précision et simplicité.

Enfin, les courbes polynomiales retenues ont été tracées sur les nuages de points pour chaque groupe (filles/garçons dans chaque pays), afin de visualiser la qualité de l'ajustement.

a) La taille des garçons en République Dominicaine




Dans ce graphique, nous avons représenté la taille des garçons en fonction de l'âge en République Dominicaine, avec les différentes courbes issues de l'ajustement polynomial.

Nous avons testé plusieurs modèles de régression polynomiale, du **degré 1 à 7**, et calculé leur **AIC** respectif : Degré 1 : 11677.59 ; Degré 2 : 10963.03 ; Degré 3 : 10451.32 ; Degré 4 : 10366.24 ; Degré 5 : 10327.86 ; **Degré 6 : 10301.82** ; Degré 7 : 10302.25.

L'AIC est minimum pour un polynôme d'ordre 6, c'est donc le modèle le plus pertinent selon ce critère, car il fournit le meilleur compromis entre qualité de l'ajustement et complexité du modèle.

La courbe obtenue avec ce modèle s'ajuste bien à la tendance générale des données sans sur-ajustement, et permet de visualiser efficacement la croissance des garçons en République Dominicaine.

b) La taille des filles en République Dominicaine




Ce graphique montre la taille des filles en République Dominicaine selon l'âge, modélisée par des polynômes de degrés 1 à 7 pour trouver le meilleur compromis entre précision et simplicité. Voici les valeurs d'AIC pour chaque degré : Degré 1 : 12661,72 ; Degré 2 : 10475,70 ; Degré 3 : 10291,16 ; Degré 4 : 10136,91 ; Degré 5 : 10110,06 ; **Degré 6 : 10105,19** et Degré 7 : 10107,15.

L'AIC baisse beaucoup entre les premiers degrés, de plus de 12600 à environ 10100 pour les modèles plus complexes. L'amélioration est

notable jusqu'au degré 6, où l'AIC est le plus bas. Au-delà, le degré 7 n'améliore pas vraiment le modèle.

Ainsi, le **polynôme de degré 6 est le meilleur choix selon l'AIC** : il décrit bien la croissance sans être trop compliqué, et représente fidèlement les variations de taille des filles pendant leur développement.

c) La taille des garçons au Sri Lanka




Ce graphique montre la taille des garçons au Sri Lanka en fonction de l'âge, modélisée avec des polynômes de degrés différents. L'analyse des valeurs d'AIC montre une nette amélioration de l'ajustement quand le degré augmente, surtout entre les degrés 1 et 3. Après cela, les gains sont plus modestes, avec un minimum à partir du degré 6. Le degré 7 n'apporte pas d'amélioration significative.

Voici les valeurs d'AIC pour chaque degré : Degré 1 : 11482,22 ; Degré 2 : 10919,14 ; Degré 3 : 10463,66 ; Degré 4 : 10419,68 ; Degré 5 : 10381,31 ; **Degré 6 : 10369,12** ; Degré 7 : 10370,55

Le **modèle de degré 6** est donc un bon compromis entre précision et simplicité, capturant bien les variations de croissance des garçons au Sri Lanka sans être trop complexe.

d) La taille des filles au Sri Lanka



Ce graphique illustre la taille des filles au Sri Lanka en fonction de l'âge, modélisée par des polynômes de degrés croissants. On observe une amélioration notable du critère AIC entre le degré 1 et le degré 6, avec une baisse importante de la valeur. Ensuite, l'amélioration ralentit, le degré 7 n'apportant pas de réduction significative de l'AIC.

Voici les valeurs d'AIC par degré : Degré 1 : 12505,74 ; Degré 2 : 10509,07 ; Degré 3 : 10282,87 ; Degré 4 : 10163,97 ; Degré 5 : 10130,97 ; **Degré 6 : 10120,35** ; Degré 7 : 10122,02.


Cela montre que le **modèle polynomial de degré 6 est le plus adapté**, car il équilibre bien précision et simplicité. Ce modèle rend compte efficacement des variations de taille chez les filles au Sri Lanka au fil des années.

Après l'ajustement polynomial, nous avons analysé la répartition des tailles par classe d'âge à l'aide des quantiles.

3. ANALYSE PAR CLASSE D'ÂGE : COURBES DE MEDIANE, 1ER ET 3E QUARTILE

Pour représenter les courbes de croissance, nous avons d'abord divisé la population en classes d'âge précises : [5,6], [6,7], [7,8], [8,9], [9,10], [10,11], [11,12], [12,13], [13,14], [14,15], [15,16], [16,17], [17,18], et [18,19]. Pour cela, nous avons utilisé la fonction **cut()** dans R. Pour chaque classe d'âge, nous avons calculé trois indicateurs statistiques : la médiane, le premier quartile (Q1) et le troisième quartile (Q3) de la taille. La médiane, représentée par une courbe rouge, indique la taille centrale de chaque groupe d'âge, tandis que la courbe bleue pour le Q1 et la courbe verte pour le Q3 montrent la dispersion inférieure et supérieure des tailles respectivement. Ces valeurs ont été obtenues grâce aux fonctions **tapply()** pour appliquer les calculs sur chaque groupe, et **quantile()** pour extraire les quartiles. Ces courbes permettent de visualiser clairement l'évolution de la taille médiane selon l'âge ainsi que la variabilité autour de cette valeur centrale. Cette méthode offre ainsi une compréhension détaillée des trajectoires de croissance et des différences possibles entre les groupes d'âge.

a) La croissance des garçons en République Dominicaine




L'analyse des quantiles montre que la courbe du premier quartile reste basse avec peu d'observations en dessous, ce qui indique une faible proportion de garçons de petite taille. La médiane est bien centrée, reflétant fidèlement la taille typique à chaque âge. La courbe du troisième quartile se situe en haut du nuage de points, avec de nombreuses valeurs au-dessus, ce qui traduit une plus grande variabilité chez les garçons les plus grands.

Entre 6 et 16 ans, les trois courbes progressent de façon marquée, signalant une phase de croissance rapide. À 16 ans, elles atteignent environ 169 cm (Q1), 172 cm (médiane) et 174,5 cm (Q3). Entre 16 et 17 ans, une légère baisse est observée, puis les tailles se stabilisent entre 165 et 180 cm après 17 ans, ce qui marque l'atteinte de la taille adulte.

On en déduit que la croissance des garçons en République Dominicaine suit un schéma classique : une forte progression pendant l'enfance et l'adolescence, suivie d'un ralentissement, puis d'une stabilisation. La dispersion croissante autour du troisième quartile dans les âges élevés suggère aussi une variabilité individuelle accrue à la fin de la croissance.

b) La croissance des filles en République Dominicaine




Ce graphique présente la distribution de la taille des filles en République Dominicaine selon l'âge. Entre 6 et 13 ans, on observe une augmentation régulière des trois courbes (Q1, médiane et Q3), indiquant une phase de croissance rapide. À 13 ans, la médiane atteint environ 156 cm, Q1 est autour de 153,8 cm, et Q3 près de 157,9 cm, ce qui traduit un développement corporel important à cette période.

À partir de 14 ans, la croissance ralentit nettement : les courbes se stabilisent. Entre 15 et 19 ans, la

médiane reste autour de 158 cm, Q1 autour de 156 cm, et Q3 autour de 161 cm. Cela montre que la majorité des filles atteignent leur taille adulte dès 14-15 ans.

On en déduit que la croissance des filles en République Dominicaine est plus rapide et se stabilise plus tôt que chez les garçons. Dès 14 ans, la taille varie davantage entre individus, comme le montre l'écart croissant entre Q1 et Q3.

c) La croissance des garçons au Sri Lanka



Ce graphique montre la distribution de la taille des garçons au Sri Lanka selon l'âge, de 5 à 19 ans. Les trois courbes (Q1, médiane et Q3) augmentent régulièrement sur toute la période, ce qui reflète aussi une croissance continue.


Entre 5 et 13 ans, la taille médiane passe de 105,6 cm à 151,1 cm. Q1 évolue de 103,8 cm à 148,7 cm, et Q3 de 107,4 cm à 153,7 cm. Cela indique une croissance corporelle régulière pendant l'enfance.

De 13 à 15 ans, la croissance reste rapide : la médiane atteint près de 156 cm à 14-15 ans, puis environ 160,5 cm à 15-16 ans. Q1 et Q3 progressent également, ce qui montre que la majorité des garçons sont encore en pleine croissance.

Après 16 ans, la croissance ralentit. La médiane atteint environ 165,7 cm à 18-19 ans, Q1 se stabilise autour de 162,8 cm, et Q3 autour de 168,4 cm. L'écart entre Q1 et Q3 reste stable, ce qui traduit une variabilité modérée des tailles.

On en déduit que la croissance des garçons au Sri Lanka est régulière et prolongée, avec une stabilisation vers la fin de l'adolescence. Elle s'étale donc sur une période plus longue qu'en République Dominicaine, où la taille adulte est atteinte plus tôt.

d) La croissance des filles au Sri Lanka



Ce graphique montre la distribution de la taille des filles au Sri Lanka en fonction de l'âge, de 5 à 19 ans.

Nous pouvons voir qu'entre 5 et 13 ans, la taille médiane passe de 107,3 cm à 146,3 cm. Q1 évolue de 105,4 cm à 144,0 cm, et Q3 de 109,1 cm à 148,1 cm. Cette progression indique une croissance corporelle stable durant l'enfance.

Entre 13 et 15 ans, la croissance ralentit nettement : la médiane atteint environ 151,4 cm à 14-15 ans, puis 152,6 cm à 15-16 ans. Q1 et Q3 suivent le même ralentissement, suggérant que la

majorité des filles atteignent leur taille adulte à cet âge.

Au-delà de 16 ans, les courbes restent quasiment stables. La médiane atteint 154,2 cm à 18-19 ans, Q1 reste autour de 151,6 cm et Q3 à 156,2 cm, ce qui confirme la fin de la croissance.

On en déduit que la croissance des filles au Sri Lanka est régulière jusqu'à environ 13 ans, puis ralentit rapidement. La stabilisation de la taille intervient tôt, autour de 15-16 ans, plus précocement que chez les garçons.

CONCLUSION

The analysis of growth data for children aged 5 to 19 in the Dominican Republic and Sri Lanka highlights significant differences between sexes as well as between these two countries.

First of all, boys are generally taller than girls in both countries, with a greater dispersion of sizes among boys. This trend is consistent with biological knowledge about growth. Comparing the two countries, individuals from the Dominican Republic show higher median sizes than those from Sri Lanka, which suggests differences related to genetic or environmental factors.

Thus, the individuals of the Dominican Republic are larger. The modeling by polynomial regression, optimized by the AIC criterion, made it possible to accurately describe the growth curves. Degree 6 was chosen in all cases as the best compromise between complexity and quality of fit.

The median and quartile curves show that growth is rapid, generally between 5 and 15-16 years, followed by a slowdown and then stabilization towards the end of adolescence. Girls reach their adult height earlier than boys, a phenomenon well illustrated in both countries.

These results show that it is important to look at growth by gender and country. They can help to better understand and monitor the health of individuals in different places.

ANNEXE

Code R

Aperçu du code R sur les analyses descriptives

```
1 rm(list=ls())
2 setwd("C:/Users/ACER/Desktop/BUT1/R/SAE Régression")
3 .libPaths("C:/Users/ACER/Desktop/BUT1/R/Packages")
4 load(file = "Data_Projet23.Rdata")
5 library(MASS)
6 #install.packages("ascentTraining")
7 library(ascentTraining)
8 #install.packages("robustTest")
9 library(robustTest)
10 library(dplyr)
11 summary(Data)
12 library(skimr)
13 skim(Data)
14 library(ggplot2)
15 library(tidyverse)
16
17 #Analyse descriptive des variables
18 #univarié
19 #Age
20 boxplot(Data$Age,main="Répartition de l'age", col = "bisque3")
21
22 #Taille
23 boxplot(Data$Taille,main="Répartition de la taille", col = "azure2")
24 #bivariée
25 #Taille Sexe
26 by(Data$Taille, Data$Sexe, summary)
27 boxplot(Data$Taille ~ Data$Sexe, col = c("lightblue", "lightgreen"),
28         main = "Répartition de la taille selon le sexe",
29         xlab = "sexe",
30         ylab = "Taille")
31 #Sexe Age
32 by(Data$Age, Data$Sexe, summary)
33 boxplot(Data$Age ~ Data$Sexe, col = c("lightblue", "lightgreen"),
34         main = "Répartition de l'age selon le sexe",
35         xlab = "Sexe",
36         ylab = "Age")
37 levels(Data$Sexe)
38
39 #Taille Pays
40 by(Data$Taille, Data$Pays, summary)
41 boxplot(Data$Taille ~ Data$Pays, col = c("bisque", "darkolivegreen3"),
42         main = "Répartition de la taille selon le Pays",
43         xlab = "Pays",
44         ylab = "Taille")
45
46 #Age Pays
47 by(Data$Age, Data$Pays, summary)
48 boxplot(Data$Age ~ Data$Pays, col = c("bisque", "darkolivegreen3"),
49         main = "Répartition de l'age selon le Pays",
50         xlab = "Pays",
51         ylab = "Age")
```

Aperçu du code R sur l'Ajustement polynomial

```
99 #AJUSTEMENT POLYNOMIAL
100 #RDB
101 model_RDB2 <- lm(data = RDB, Taille~Age+I(Age^2))
102 summary(model_RDB2)
103
104 model_RDB3 <- lm(data = RDB, Taille~Age+I(Age^2)+I(Age^3))
105 summary(model_RDB3)
106 model_RDB4 <- lm(data = RDB, Taille~Age+I(Age^2)+I(Age^3)+ I(Age^4))
107 summary(model_RDB4)
108 model_RDB5 <- lm(data = RDB, Taille~Age+I(Age^2)+I(Age^3)+ I(Age^4)+ I(Age^5))
109 summary(model_RDB5)
110 model_RDB6 <- lm(data = RDB, Taille~Age+I(Age^2)+I(Age^3)+ I(Age^4)+ I(Age^5)+ I(Age^6))
111 summary(model_RDB6)
112 model_RDB7 <- lm(data = RDB, Taille~Age+I(Age^2)+I(Age^3)+ I(Age^4)+ I(Age^5)+ I(Age^6)+ I(Age^7))
113 summary(model_RDB7)
114
115 #RDB
116 AIC(model_RDB)
117 AIC(model_RDB2)
118 AIC(model_RDB3)
119 AIC(model_RDB4)
120 AIC(model_RDB5)
121 AIC(model_RDB6)
122 AIC(model_RDB7)
123
124
125 plot(RDB$Age,
126      RDB$Taille,
127      main="Variation de la taille des garçons au Dominican Republic en fonction de leur âge",
128      xlab="Age",
129      ylab="Taille")
130 abline(model_RDB,col="red", lwd = 2)
131 x = seq(min(RDB$Age), max(RDB$Age), by = 0.5)
132
133 polRDB2 = coefficients(model_RDB2)[1] + coefficients(model_RDB2)[2]*x + coefficients(model_RDB2)[3]*x^2
134 lines(x, polRDB2, col = "blue", lwd = 2)
135
136 polRDB3 = coefficients(model_RDB3)[1] + coefficients(model_RDB3)[2]*x + coefficients(model_RDB3)[3]*x^2
137 + coefficients(model_RDB3)[4]*x^3
138 lines(x, polRDB3, col = "green", lwd = 2)
139
140 polRDB4 = coefficients(model_RDB4)[1] + coefficients(model_RDB4)[2]*x + coefficients(model_RDB4)[3]*x^2
141 + coefficients(model_RDB4)[4]*x^3 + coefficients(model_RDB4)[5]*x^4
142 lines(x, polRDB4, col = "pink", lwd = 2)
143
144 polRDB5 = coefficients(model_RDB5)[1] + coefficients(model_RDB5)[2]*x + coefficients(model_RDB5)[3]*x^2
145 + coefficients(model_RDB5)[4]*x^3 + coefficients(model_RDB5)[5]*x^4 + coefficients(model_RDB5)[6]*x^5
146 lines(x, polRDB5, col = "brown", lwd = 2)
147
148 polRDB6 = coefficients(model_RDB6)[1] + coefficients(model_RDB6)[2]*x + coefficients(model_RDB6)[3]*x^2
149 + coefficients(model_RDB6)[4]*x^3 + coefficients(model_RDB6)[5]*x^4 + coefficients(model_RDB6)[6]*x^5
150 + coefficients(model_RDB6)[7]*x^6
151 lines(x, polRDB6, col = "orange", lwd = 3)
152
153 legend("topleft", title = "Ajustement polynomial",
154       legend = c("Linéaire (deg 1)", "Polynôme deg 2", "Polynôme deg 3", "Polynôme deg 4", "Polynôme deg 5", "Polynôme deg 6"),
155       col = c("red", "blue", "green", "pink", "brown", "orange"),
156       lwd = c(2,2,2,2,3,3))
```

Aperçu du code R sur l'Analyse des quantiles

```
310 #ANALYSE PAR QUANTILE
311 #RDB
312 newx <- cut(RDB$Age, breaks = c(5,6,7,8,9,10,11,12,13,14,15,16,17,18,19))
313 levels(newx)
314 table(newx)
315 newy <- tapply(RDB$Taille, newx, median)
316 quar1 = function(x){
317   quantile(x,0.25)
318 }
319
320 newy2 <- tapply(RDB$Taille, newx, quar1)
321 quar3 = function(x){
322   quantile(x,0.75)
323 }
324 newy3 <- tapply(RDB$Taille, newx, quar3)
325
326 par(mfrow=c(1,1))
327 plot(RDB$Age, RDB$Taille, main = "Distribution de la taille des garçons au Dominican Republic par classe d'âge",
328      xlab = "Age",
329      ylab = "Taille")
330 lines(6:19, newy, col=2, lwd=3)
331 lines(6:19, newy2, col="blue", lwd=2)
332 lines(6:19, newy3, col="green", lwd=2)
333
334 legend("topleft",
335       legend = c("1er quartile (Q1)", "Médiane", "3e quartile (Q3)"),
336       col = c("blue", "red", "green"),
337       lwd = c(2, 3, 2))
```